


S3 Step 1 — Grad-weighted rollout (Head 3)

$\mu = 0.06250$

$\sigma = 0.117890$

Target token i

[CLS]	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.13
it	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.13
,	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
s	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
a	0.50	0.02	0.04	0.03	0.03	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
bit	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
slow	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
at	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
times	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
but	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.13
the	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
performances	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
are	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.13
outstanding	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.07	0.14
.	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.08	0.14
[SEP]	0.50	0.02	0.04	0.03	0.02	0.02	0.01	0.02	0.02	0.02	0.03	0.02	0.02	0.02	0.08	0.14



[CLS] it , s a bit slow at times but the performances are outstanding [SEP]

Source token j