


S3 Step 1 — Grad-weighted rollout (Head 8)

$\mu = 0.06250$

$\sigma = 0.119034$

Target token i

[CLS]	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
it	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
,	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
s	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
a	0.49	0.02	0.04	0.02	0.03	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
bit	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
slow	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
at	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
times	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
but	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
the	0.49	0.02	0.04	0.02	0.02	0.02	0.02	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
performances	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
are	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
outstanding	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
.	0.49	0.02	0.04	0.02	0.02	0.02	0.01	0.02	0.01	0.02	0.02	0.02	0.02	0.01	0.04	0.21
[SEP]	0.49	0.02	0.04	0.02	0.02	0.01	0.01	0.02	0.01	0.02	0.02	0.01	0.02	0.01	0.04	0.21



[CLS] it , s a bit slow at times but the performances are outstanding [SEP]

Source token j