


S4 Step 1 — Grad-weighted rollout (Head 12)

$\mu = 0.07692$

$\sigma = 0.148485$

Target token i

[CLS]	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.14
a	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15
dull	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15
,	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15
ted	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.02	0.02	0.02	0.15
##ious	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15
and	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.14
completely	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.04	0.04	0.03	0.02	0.02	0.14
forget	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.04	0.04	0.03	0.02	0.02	0.14
##table	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.04	0.04	0.03	0.02	0.02	0.14
experience	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.14
.	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15
[SEP]	0.58	0.04	0.02	0.02	0.01	0.03	0.02	0.03	0.04	0.03	0.02	0.02	0.15



Source token j

[CLS] a dull , ted ##ious and completely forget ##table experience . [SEP]