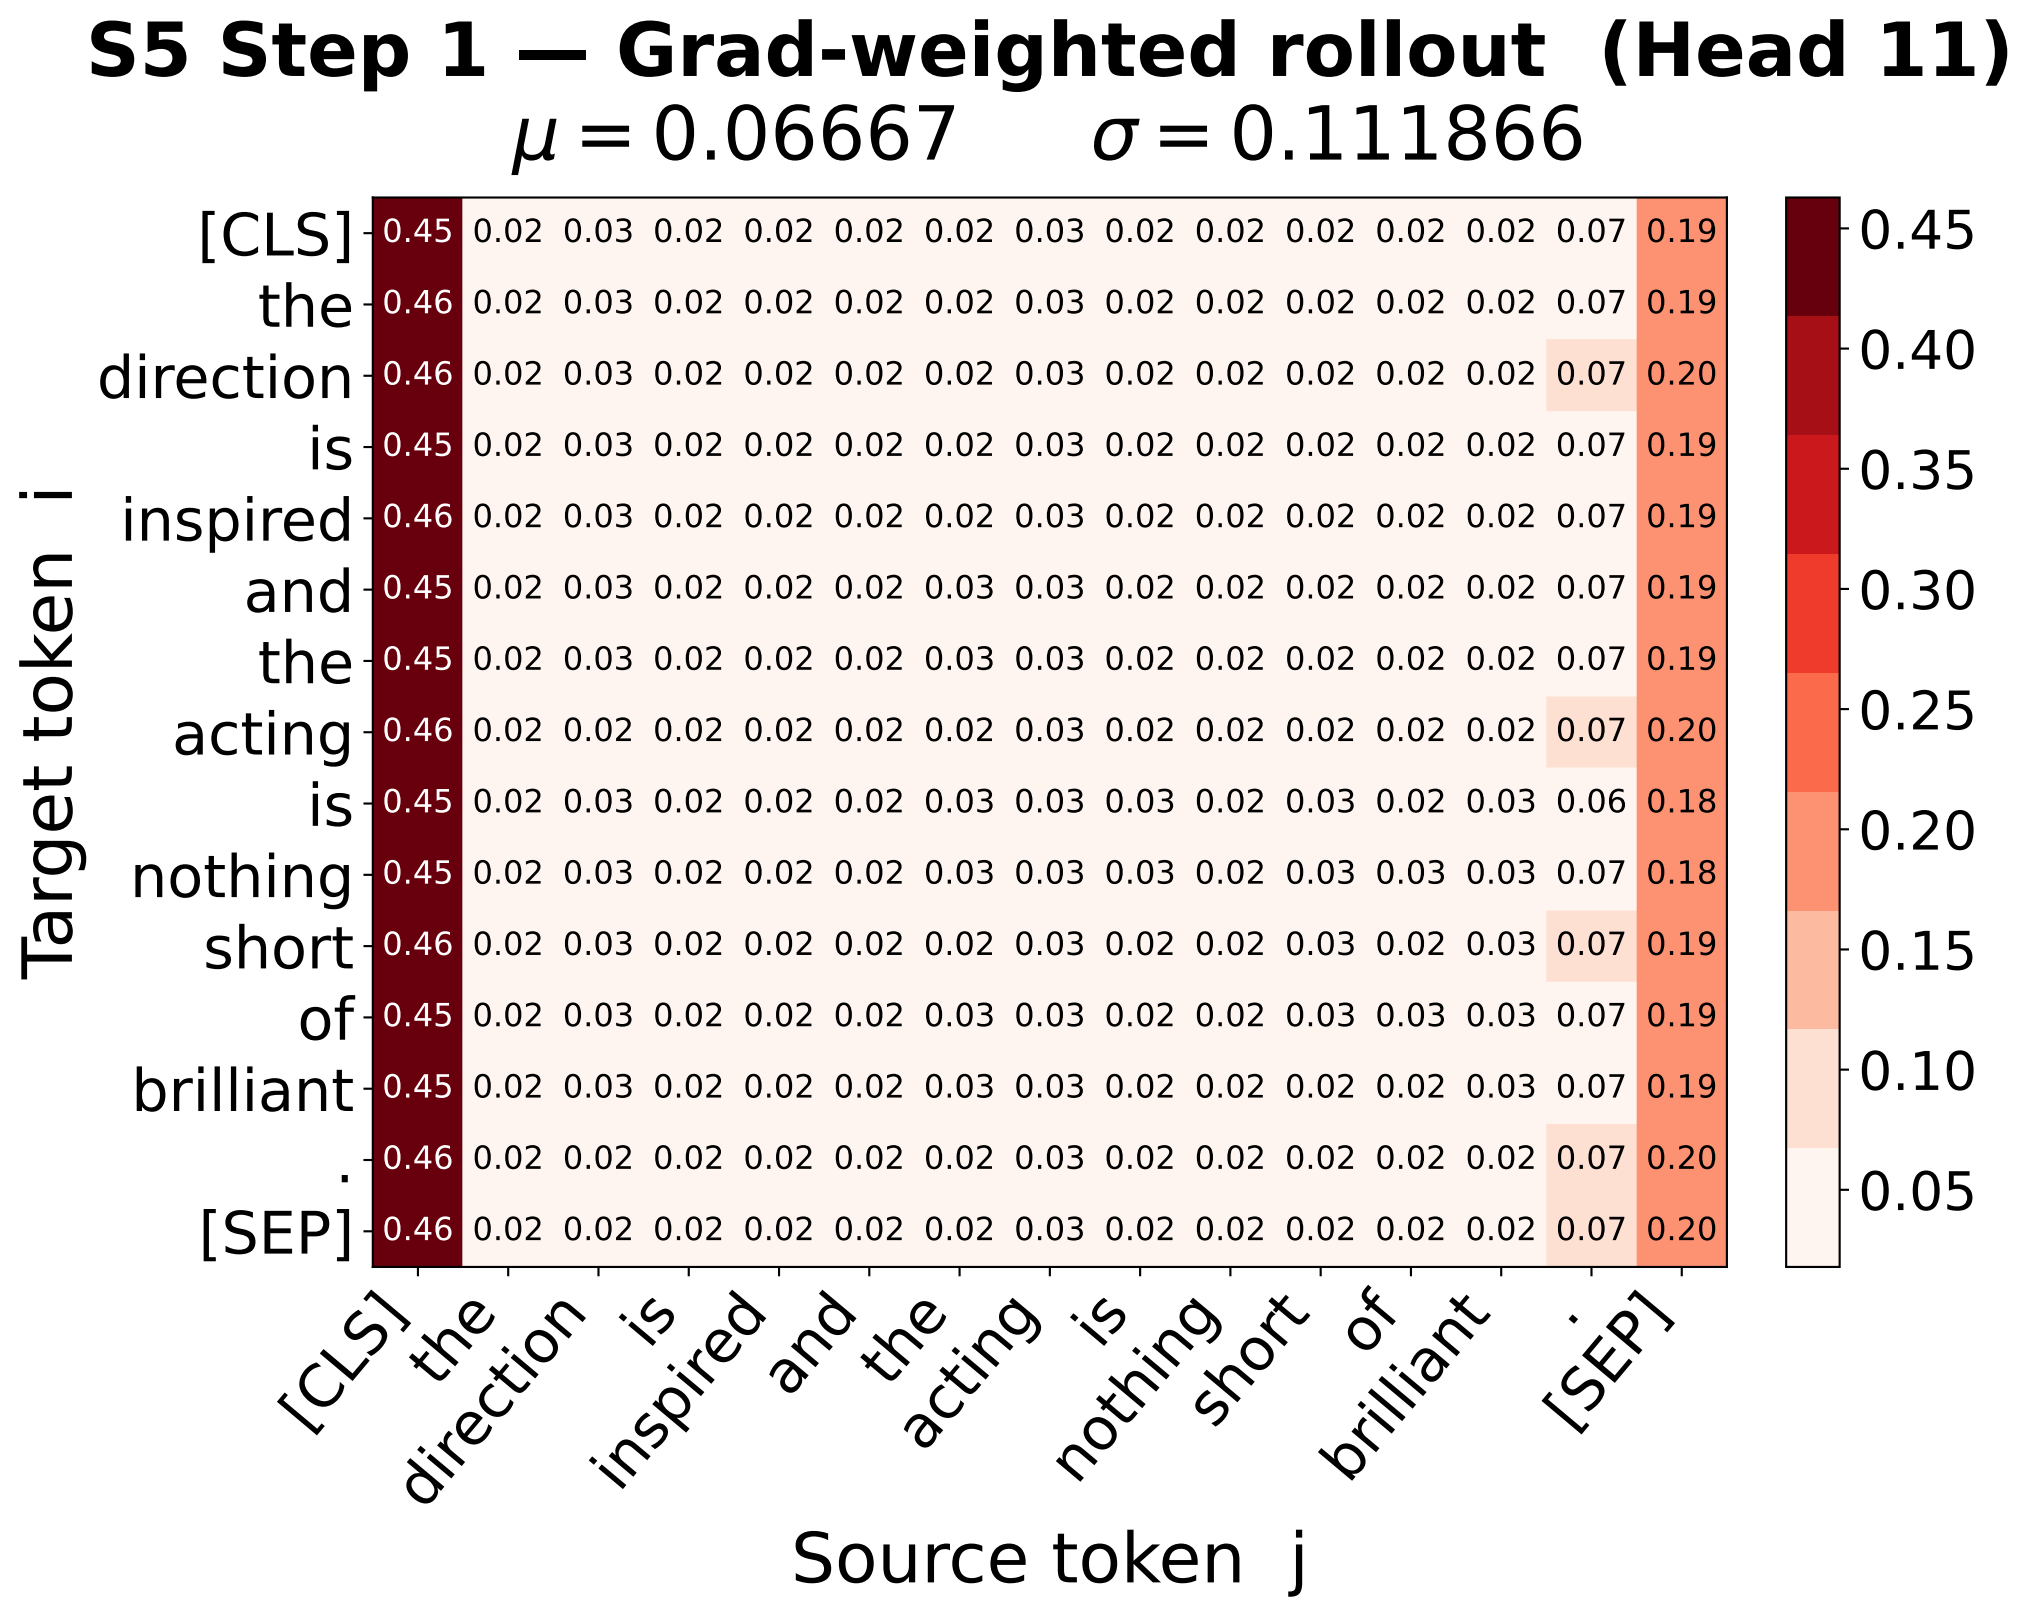
S5 Step 1 — Grad-weighted rollout (Head 11)
$\mu = 0.06667$ $\sigma = 0.111866$
Target token i
Source token j
[CLS] 0.45 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
the 0.46 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
direction 0.46 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.20
is 0.45 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
inspired 0.46 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
and 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
the 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.19
acting 0.46 0.02 0.02 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.20
is 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.03 0.02 0.03 0.02 0.03 0.06 0.18
nothing 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.03 0.02 0.03 0.03 0.03 0.07 0.18
short 0.46 0.02 0.03 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.03 0.02 0.03 0.07 0.19
of 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.02 0.02 0.03 0.03 0.03 0.07 0.19
brilliant 0.45 0.02 0.03 0.02 0.02 0.02 0.03 0.03 0.02 0.02 0.02 0.02 0.03 0.07 0.19
. 0.46 0.02 0.02 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.20
[SEP] 0.46 0.02 0.02 0.02 0.02 0.02 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.07 0.20
[CLS] the direction is inspired and the acting is nothing short of brilliant . [SEP]
0.45 0.40 0.35 0.30 0.25 0.20 0.15 0.10 0.05