


S9 Step 1 — Per-head rollout (Head 5)

$\mu = 0.06250$

$\sigma = 0.088608$

Target token i

[CLS]	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
a	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
hollow	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
and	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
disappointin	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
sequel	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
that	-0.35	0.03	0.03	0.03	0.03	0.04	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
betray	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
##s	-0.35	0.03	0.03	0.03	0.03	0.04	0.02	0.03	0.03	0.03	0.03	0.03	0.03	0.03	0.04	0.22
everything	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
the	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
original	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
stood	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
for	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23
.	-0.35	0.03	0.03	0.03	0.03	0.04	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.22
[SEP]	-0.35	0.03	0.03	0.03	0.03	0.03	0.02	0.03	0.02	0.03	0.03	0.03	0.03	0.03	0.04	0.23



[CLS] a hollow and disappointin sequel that betray ##s everything the original stood for [SEP]

Source token j