

S9 Step 1 — Per-head rollout (Head 12)

$\mu = 0.06250$

$\sigma = 0.112587$

Target token i

[CLS]	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
a	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
hollow	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.02	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
and	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
disappointin	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.02	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
sequel	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.02	0.02	0.04	0.05	0.03	0.02	0.02	0.01	0.12
that	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
betray	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
##s	-0.48	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
everything	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
the	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
original	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
stood	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
for	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.03	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
.	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.02	0.02	0.05	0.05	0.03	0.03	0.02	0.01	0.12
[SEP]	-0.49	0.03	0.02	0.02	0.02	0.03	0.04	0.02	0.02	0.04	0.05	0.03	0.03	0.02	0.01	0.12



[CLS] a hollow and disappointin sequel that betray ##s everything the original stood for [SEP]

Source token j