

# S3 Step 1 — Per-head rollout (Head 8)

$\mu = 0.06250$

$\sigma = 0.119034$

Target token  $i$

|              |       |      |      |      |      |      |      |      |      |      |      |      |      |      |      |      |      |
|--------------|-------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|------|
| [CLS]        | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| it           | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| ,            | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| s            | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| a            | -0.49 | 0.02 | 0.04 | 0.02 | 0.03 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| bit          | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| slow         | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| at           | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| times        | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| but          | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| the          | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| performances | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| are          | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| outstanding  | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| .            | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.02 | 0.02 | 0.02 | 0.01 | 0.04 | 0.21 |
| [SEP]        | -0.49 | 0.02 | 0.04 | 0.02 | 0.02 | 0.01 | 0.01 | 0.02 | 0.01 | 0.02 | 0.02 | 0.01 | 0.02 | 0.01 | 0.04 | 0.21 |      |



Source token  $j$

[CLS] it , s a bit slow at times but the performances are outstanding [SEP]