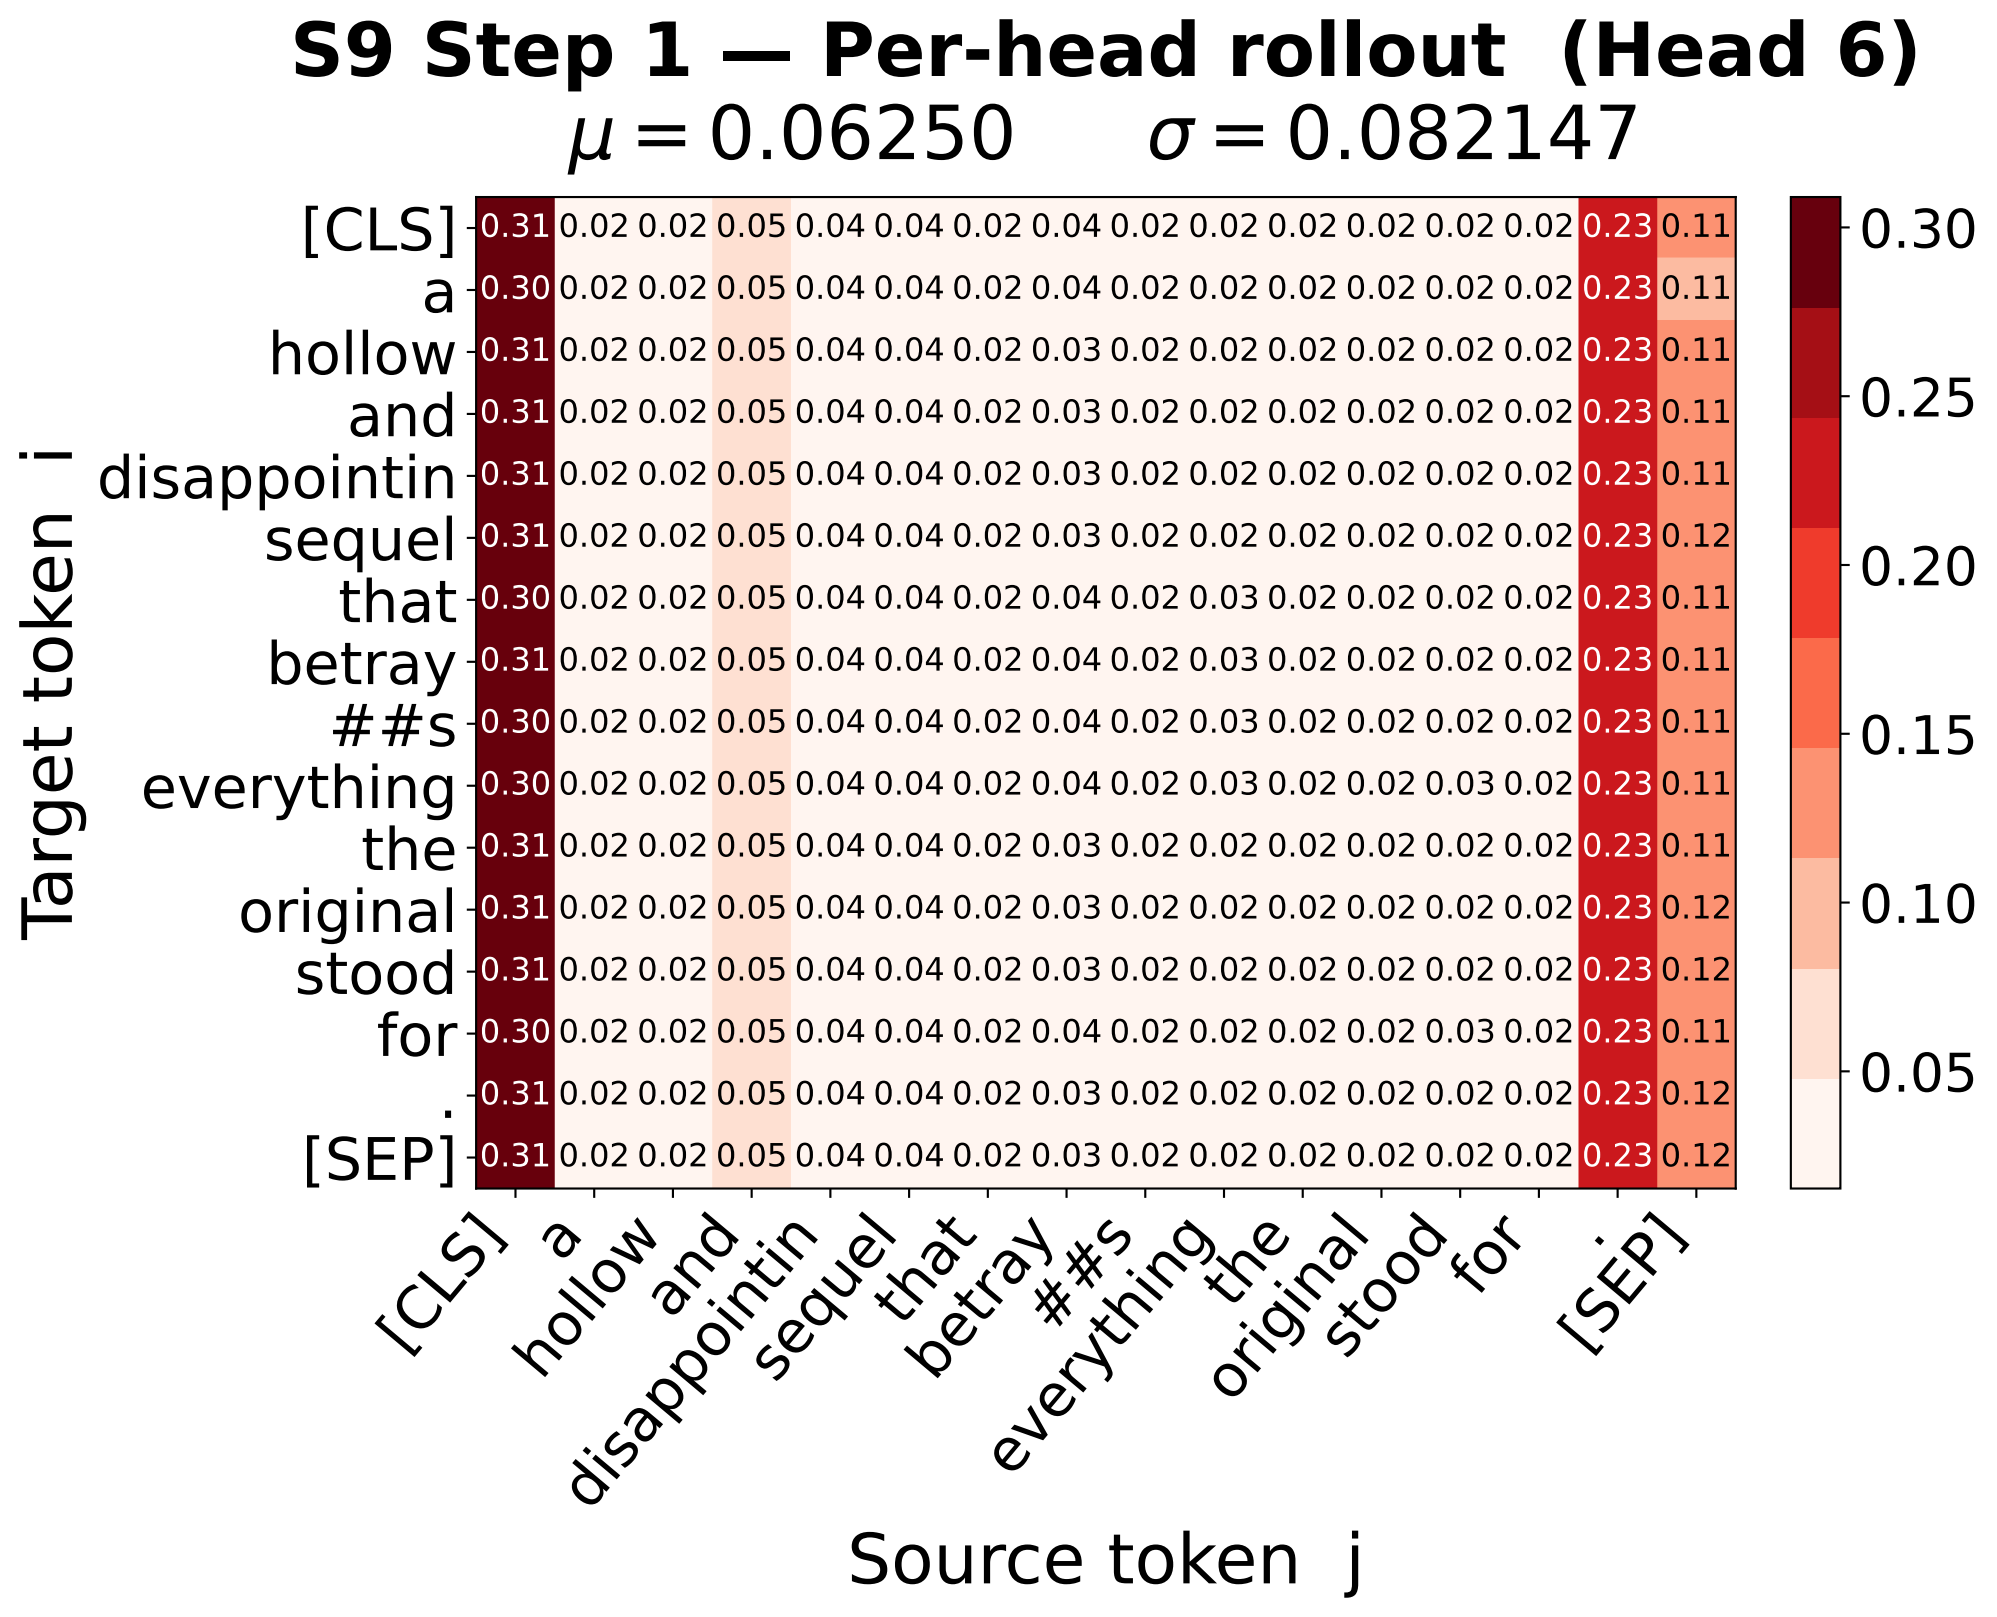

S9 Step 1 — Per-head rollout (Head 6)
$\mu = 0.06250$ $\sigma = 0.082147$
Target token i
Source token j
[CLS] 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
a 0.30 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
hollow 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
and 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
disappointin 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
sequel 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.12
that 0.30 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.23 0.11
betray 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.23 0.11
##s 0.30 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.23 0.11
everything 0.30 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.03 0.02 0.02 0.03 0.02 0.23 0.11
the 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.11
original 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.12
stood 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.12
for 0.30 0.02 0.02 0.05 0.04 0.04 0.02 0.04 0.02 0.02 0.02 0.02 0.03 0.02 0.23 0.11
. 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.12
[SEP] 0.31 0.02 0.02 0.05 0.04 0.04 0.02 0.03 0.02 0.02 0.02 0.02 0.02 0.02 0.23 0.12
[CLS] a hollow and disappointin sequel that betray ##s everything the original stood for . [SEP]
0.30 0.25 0.20 0.15 0.10 0.05