


S9 Step 1 — Per-head rollout (Head 7)

$\mu = 0.06250$

$\sigma = 0.072097$

Target token i

[CLS]	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
a	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
hollow	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
and	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
disappointin	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
sequel	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
that	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.03	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
betray	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.03	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
##s	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.03	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
everything	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.03	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
the	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
original	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
stood	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.04	0.02	0.04	0.15
for	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.04	0.02	0.04	0.15
.	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15
[SEP]	0.30	0.09	0.02	0.03	0.03	0.04	0.03	0.02	0.02	0.04	0.12	0.02	0.03	0.02	0.04	0.15



[CLS] a hollow and disappointin sequel that betray ##s everything the original stood for [SEP]

Source token j